

Inteligencia artificial avanzada para la ciencia de datos

Oswaldo Isaias Hernández Santes
Instituto Tecnológico y de Estudios Superiores de Monterrey
Escuela de Ingeniería y Ciencias
Santiago de Querétaro, Querétaro; México
a01199004@tec.mx

Abstract—Este Proyecto se enfoca en la implementación manual de un algoritmo de regresión lineal utilizando la gradiente descendiente sin la asistencia o el uso de marcos de trabajo o bibliotecas externas de Machine Learning. Haciendo uso únicamente de herramientas base de Python como NumPy, Pandas y Matplotlib el objetivo principal fue desarrollar un modelo capaz de predecir con precisión la edad de los abulones basándose en sus atributos físicos. Se hizo un análisis de datos exploratorio (EDA), se limpió el data set y se transformó con técnicas como One-Hot Encoding y estandarización lo que permitió un entrenamiento decente.

Para evaluar la capacidad del modelo se implementó una función de costo basada en el Error Cuadrático Medio (MSE, por sus siglas en inglés), se midió el desempeño utilizando un conjunto de entrenamiento, validación y prueba. Los resultados obtenidos demostraron que el algoritmo alcanzó un punto mínimo de error y obtuvo un nivel de ajuste *fitt* con un nivel bajo tanto de sesgo como de varianza. (*Abstract*)

Keywords—Regresión Lineal, Gradiente Descendiente, ANálisis Exploratorio de Datos (EDA), Machine Learning (ML), Error Cuadrático Medio (MSE), NumPy, Pandas, One-Hot Encoding, Varianza, Sesgo, Underfitting/Overfitting. (*key words*)

I. INTRODUCTION

A. Contexto general

La inteligencia artificial (IA) y el aprendizaje automático (Machine Learning o ML) han cambiado la forma en que se analiza la información y se resuelven problemas complejos, el aprendizaje supervisado se encarga de entrenar modelos utilizando conjuntos de datos para predecir atributos de interés, también existen algoritmos que su principal función es clasificar.

En el contexto de este proyecto la regresión lineal se presenta como una herramienta fundamental para resolver problemas de predicción, en comparación con la regresión logística (que se usa para clasificación binaria) la regresión lineal busca encontrar la relación entre variables independientes y una variable dependiente numérica.

Para poder lograrlo el modelo implementa el algoritmo de la gradiente descendiente el cual es un algoritmo de optimización y minimiza iterativamente una función de costo, en este caso se usó MSE, se hace mediante el cálculo de las derivadas parciales que ajustan los pesos (w) y el sesgo (b) del modelo, esto permite el aprendizaje del modelo y mejora sus predicciones.

B. Base de datos

El conjunto de datos utilizado en este proyecto proviene del data set Abalone, estos datos contienen descripciones físicas de muestras de abulones que permiten predecir la edad de estos sin necesidad de cortar la concha y contar sus anillos, originalmente este conjunto de datos cuenta con 4176 instancias distribuidas en los siguientes atributos de predicción:

- Sex: es una variable categórica que representa el sexo (M, F, I).
- Length: Longitud del abulón.
- Diameter: Diámetro del abulón.
- Height: Altura del abulón.
- Whole weight: Peso total o entero.
- Shucked weight: Peso de la carne o peso sin concha.
- Viscera weight: Peso de las vísceras.
- Shell weight: Peso de la concha.

II. ANÁLISIS EXPLORATORIO DE DATOS

El Análisis Exploratorio de Datos (EDA) tiene como finalidad comprender la estructura del data set e identificar posibles patrones, relaciones o errores en la información original. Con motivo de tener un data set lo más limpio posible este mismo fue procesado con ayuda de la biblioteca de Pandas de Python, facilitó la examinación y manipulación de las 4176 instancias originales, las técnicas que se usaron en esta etapa pueden garantizar que el algoritmo matemático reciba datos limpios y equilibrados.

A. Revisión y detección

Durante la inspección de los datos con la estadística descriptiva del data set se detectó una inconsistencia biológica en los datos, el atributo Height contenía un valor mínimo de 0, se aislaron las instancias inusuales y después de analizarlas se encontró que eran 2 instancias pertenecientes al tipo de sexo infantil ($\text{Sex} = 'I'$), al contar de manera general el número de instancias totales de este tipo de sexo se encontró que el data set contaba con 1342 instancias de este mismo, se observó que estos 2 datos representaban una parte muy pequeña de este tipo y se decidió eliminar estas instancias del data set principal, esto permitió eliminar parte del ruido que puede afectar al modelo de predicción.

B. Transformación de Datos y Visualización

Otra parte fundamental del preprocesamiento del data set fue adaptar la variable categórica “Sex” para que fueran representados por valores numéricos, debido a que el modelo de regresión lineal funciona con valores numéricos continuos asignar valores secuenciales como 0, 1 y 2 pudo provocar que el modelo interpretara pesos o magnitudes entre los sexos el cual no debe de existir.

Para evitarlo se aplicó una técnica de One-Hot Encoding usando la función de pandas `get_dummies()` el cual transforma el atributo original en tres nuevos atributos que usan ceros y unos para identificar el sexo de la instancia M, F o I.

También se generó una matriz de dispersión usando la biblioteca Matplotlib, esta matriz permitió la visualización del data set en un esquema de “todos contra todos”, esto ayudó a identificar posibles anomalías no vistas en el data set y además a la selección del modelo a usar, la gráfica obtenida sirvió para ver que la mayoría de los datos tenían relaciones lineales y se optó por usar un modelo de regresión lineal.

Para elegir los atributos que se conservaron para el entrenamiento del modelo se generó una matriz de correlación el cual reveló el nivel de relación de los atributos físicos y la edad del abulón, se encontró que el peso de la concha tuvo una mayor correlación de 0.628 siendo el atributo más fuerte, puedo inferir que esto tiene sentido ya que con el tiempo el caparazón crece, otro de los atributos son el diámetro con 0.547, la altura con 0.558 y la longitud con 0.556, permitió al algoritmo evaluar el tamaño de los caparazones en relación con los anillos.

Los atributos como el peso completo con 0.540, el peso de las vísceras con 0.504 y el peso de la carne sin concha con 0.420 son correlaciones no tan altas, pero se decidió conservar estos atributos para que el modelo contemple la proporción entre la masa interna y el caparazón, esto evitó sesgos con abulones de peso vacío.

Por último, la variable categórica “Sex” debido a que existen diferentes tasas de crecimiento dependiendo del género se decidió aplicar la técnica de One-Hot Encoding para mantener esta información.

C. Estandarización de los datos

Como parte del preprocesamiento para el algoritmo de la gradiente descendiente se estandarizó el data set mediante escalamiento con un método llamado Z-score el cual ajusta los atributos para que usen una escala uniforme, sin el uso de este mismo los atributos con magnitudes mayores serían más relevantes en el cálculo del error y esto a su vez impediría el aprendizaje del modelo de una manera correcta.

D. División del data set

Para poder entrenar y evaluar el modelo se dividió el data set de forma manual en tres conjuntos de datos, uno para entrenar el modelo “Train” con un 70% del data set, otro para probar el modelo y encontrar posibles áreas de oportunidad “Validation” con un 15% del total del data set y otro más para probar el modelo después de encontrar estas posibles áreas de oportunidad, también se hizo uso de la aleatoriedad para evitar sesgos por elección de instancias que se parezcan.

III. EL MODELO

A. Implementación de la regresión lineal

Para predecir la edad de los abulones se usó un algoritmo de regresión lineal que se implementa sin el uso de algún framework de ML como scikit learn, se implementó usando el framework de NumPy.

B. Gradiente descendiente y optimización

La mejora del modelo fue posible gracias al uso de la gradiente descendiente, donde dentro del modelo existieron 2 parámetros con valores nulos o aleatorios los cuales son los pesos (w) y el sesgo (b), durante cada época (ciclo completo de entrenamiento del data set completo) el algoritmo ejecutó de manera secuencial lo siguiente:

- Definió y calculó la función de hipótesis para generar predicciones.
- Evaluó la pérdida usando la función de costo MSE (Mean Squared Error) para medir incongruencias entre las edades predecidas y las reales.
- Utilizó derivadas parciales para calcular el gradiente y ver la dirección a la que se debió ajustar el modelo para reducir los errores.
- Actualizó los parámetros w y b multiplicando los gradientes por el learning rate (α en el código) elegido.

Repetir este ciclo a lo largo de cada época permitió la optimización del modelo ajustando los parámetros y así logró minimizar la función de pérdida hasta alcanzar un punto mínimo de error.

IV. EVALUACIÓN Y RESULTADOS FINALES

Para medir el rendimiento del algoritmo se usó MSE, este evaluó en cada época el desempeño del algoritmo usando un conjunto de validación (validation data), permitió ver qué tan precisas eran las predicciones con datos que el algoritmo no utilizó para actualizar sus parámetros (el peso y el sesgo).

Para visualizarlo se utilizó una gráfica generada con Matplotlib, se comparó la línea de train con la de validation dependiendo del número de épocas y el error que tenían, haciendo la comparación de ambas líneas podemos ver que son muy parecidas, el modelo no tiene overfitting que es cuando el modelo se aprende los datos de train y falla con los de validation o test porque está demasiado ajustado o el caso de underfitting que es cuando el tipo de función usada para hacer las predicciones es demasiado simple para el patrón que tiene el data set, en este caso el modelo se tiene un buen ajuste ya que al usar el conjunto de datos de test la línea es parecida de igual forma a la de train y de validation.

El grado de varianza entre cada conjunto de datos es bajo, las curvas a lo largo de las 1000 épocas se mantiene similar entre ellas mismas, el grado de sesgo es bajo ya que en la gráfica observamos que los tres conjuntos de datos disminuyen su error aproximadamente en la época 300 y se mantiene estable llegando aproximadamente a 2.5 años de error al cuadrado, debido a la estabilidad del modelo y al probar los conjuntos validation y test en el modelo se decidió no aplicar alguna técnica de regularización para mejorar el desempeño del modelo.

Finalmente, se analizaron los coeficientes finales del modelo, se encontró que el coeficiente del peso sin concha del abulón influye bastante en el dato de entrada al igual que el coeficiente del peso de la concha tiene mayor impacto, esto es significativo al momento de calcular la edad del abulón, en otras palabras cada desviación estándar que el peso de la concha sobrepasa a su media el modelo agrega aproximadamente 1.74 años a la predicción final.

V. CONCLUSIÓN

Este proyecto demuestra que es viable implementar un modelo de regresión lineal con el uso de gradiente descendiente para la predicción y aprendizaje de un modelo matemático, se pudo implementar de forma manual sin necesidad de usar frameworks para aprendizaje de máquina avanzados, también muestra cómo hacer un buen análisis de los datos para tener un modelo más preciso y menos complicado de ajustar mientras corren las épocas.

REFERENCES